

TRƯỜNG ĐẠI HỌC MỞ THÀNH PHỐ HỒ CHÍ MINH
KHOA CÔNG NGHỆ THÔNG TIN



BÁO CÁO BÀI TẬP LỚN
MÔN TRÍ TUỆ NHÂN TẠO

ĐỀ TÀI: DỰ ĐOÁN BỆNH TIỂU ĐƯỜNG
(DIABETES PREDICTION)

Sinh viên thực hiện: Nguyễn Thị Ngọc Ngoan - 2351050114

Nguyễn Lê Duy Vương - 2351050206

Nguyễn Huỳnh Như Ý - 2351050211

Võ Hồng Yến - 2351010257

GVHD

: ThS. Võ Việt Khoa

Tp.HCM - 2026

LỜI CAM ĐOAN

Chúng tôi xin cam đoan rằng báo cáo bài tập lớn đề tài "Dự đoán bệnh tiểu đường (Diabetes Prediction)" là công trình nghiên cứu và thực hiện của nhóm sinh viên chúng tôi dưới sự hướng dẫn khoa học của Giảng viên hướng dẫn ThS. Võ Việt Khoa.

Tất cả nội dung trong báo cáo, bao gồm phân tích dữ liệu, xây dựng mô hình máy học, phát triển ứng dụng và kết quả thực nghiệm, đều được thực hiện trung thực và độc lập. Các tài liệu tham khảo được trích dẫn rõ ràng và đầy đủ. Chúng tôi không sao chép hay gian lận bất kỳ nội dung nào từ các nguồn khác mà không có trích dẫn hợp lệ.

Chúng tôi hoàn toàn chịu trách nhiệm về tính trung thực và chính xác của nội dung trong báo cáo này.

TP. Hồ Chí Minh, ngày 28 tháng 4 năm 2026

Nhóm sinh viên thực hiện

LỜI CẢM ƠN

Chúng tôi xin gửi lời cảm ơn chân thành và sâu sắc nhất đến Giảng viên hướng dẫn ThS. Võ Việt Khoa – người đã tận tình chỉ dạy, định hướng nghiên cứu và hỗ trợ nhóm trong suốt quá trình thực hiện đồ án này.

Chúng tôi cũng xin gửi lời cảm ơn đến Khoa Công nghệ Thông tin, Trường Đại học Mở TP.HCM đã tạo điều kiện học tập và nghiên cứu; cảm ơn các thầy cô đã truyền đạt kiến thức và kỹ năng nền tảng về Machine Learning, phân tích dữ liệu và phát triển ứng dụng trong suốt quá trình học tập.

Chân thành cảm ơn cộng đồng nghiên cứu tại UCI Machine Learning Repository và Kaggle đã cung cấp bộ dữ liệu Pima Indians Diabetes mở, giúp nhóm có cơ hội thực hành trên dữ liệu y tế thực tế có giá trị.

Mặc dù đã cố gắng hết sức, báo cáo có thể còn một số thiếu sót. Chúng tôi rất mong nhận được sự góp ý từ thầy/cô và các bạn để hoàn thiện hơn.

Nhóm sinh viên thực hiện

TÓM TẮT

Bệnh tiểu đường là một trong những bệnh mãn tính phổ biến nhất thế giới, gây ra nhiều biến chứng nguy hiểm nếu không được phát hiện và điều trị kịp thời. Bài toán dự đoán nguy cơ mắc bệnh tiểu đường từ các chỉ số lâm sàng đặt ra yêu cầu cao về độ nhạy (Recall) nhằm hạn chế bỏ sót bệnh nhân (false negative).

Báo cáo này trình bày toàn bộ quy trình xây dựng hệ thống dự đoán bệnh tiểu đường dựa trên bộ dữ liệu Pima Indians Diabetes (768 mẫu, 8 đặc trưng lâm sàng). Quy trình gồm: Phân tích khám phá dữ liệu (EDA), xử lý giá trị thiếu ẩn dưới dạng 0 bằng trung vị, xử lý ngoại lai bằng Winsorization, kỹ thuật đặc trưng tạo thêm 3 biến mới (Glucose_BMI_Ratio, Age_Group, BMI_Category), cân bằng dữ liệu bằng SMOTE, và so sánh 5 mô hình: Logistic Regression, Random Forest, SVM, Decision Tree và Stacking Ensemble.

Kết quả: Random Forest đạt Accuracy = 0.714, Precision = 0.558, Recall = 0.889, F1-Score = 0.686, AUC = 0.864 và được chọn làm mô hình triển khai. Hệ thống được tích hợp thành ứng dụng hoàn chỉnh: Frontend ReactJS, Backend FastAPI, cơ sở dữ liệu MySQL và AI Pipeline được phục vụ qua REST API.

MỤC LỤC

LỜI CAM ĐOAN.....	1
LỜI CẢM ƠN.....	2
TÓM TẮT.....	3
CHƯƠNG 1 - GIỚI THIỆU.....	7
1.1. Mô tả bài toán và bối cảnh thực tế.....	7
1.2. Mục tiêu cụ thể.....	7
1.3. Lý do lựa chọn mô hình và metric.....	8
1.3.1. Lý do chọn mô hình Random Forest.....	8
1.3.2. Lý do ưu tiên metric Recall thay vì Accuracy.....	8
CHƯƠNG 2 - PHƯƠNG PHÁP.....	10
2.1. Mô tả Dataset.....	10
2.2. Phân tích khám phá dữ liệu (EDA).....	11
2.2.1. Phát hiện giá trị 0 bất thường (Hidden Missing Values).....	11
2.2. Kiểm định thống kê (T-test & Chi-Square).....	11
2.3. Các bước tiền xử lý dữ liệu.....	12
2.3.1. Xử lý Missing Values ẩn.....	12
2.3.2. Xử lý ngoại lai (Outlier Handling).....	12
2.3.3. Kỹ thuật đặc trưng (Feature Engineering).....	12
2.3.4. Cân bằng dữ liệu bằng SMOTE.....	12
2.4. Các mô hình đã sử dụng.....	13
2.4.1. Logistic Regression.....	13
2.4.2. Random Forest Classifier.....	13
2.4.3. Support Vector Machine (SVM).....	13
2.4.4. Decision Tree.....	13

2.4.5. Stacking Ensemble.....	14
CHƯƠNG 3 - KẾT QUẢ.....	15
3.1. Bảng so sánh các mô hình.....	15
3.2. Biểu đồ đánh giá mô hình được chọn (Random Forest).....	16
3.2.1. Các chỉ số hiệu suất của mô hình (metrics).....	16
3.2.2. Ma trận nhầm lẫn (Confusion Matrix).....	16
3.2.3. Đường cong ROC và chỉ số AUC.....	18
3.2.4. Đường cong học (Learning Curve).....	20
3.2.5. Top 10 đặc trưng quan trọng (Feature Importance).....	22
3.3. Lý do chọn Random Forest làm mô hình triển khai.....	24
CHƯƠNG 4 - ỨNG DỤNG THỰC TẾ.....	25
4.1. Scenario sử dụng.....	25
4.1.1. Kịch bản 1: Sàng lọc bệnh nhân tại cơ sở y tế.....	25
4.1.2. Kịch bản 2: Theo dõi sức khỏe cá nhân.....	25
4.2. Hạn chế khi triển khai.....	25
4.2.1. Hạn chế về dữ liệu.....	25
4.2.2. Hạn chế về môi trường và kỹ thuật.....	26
4.2.3. Hạn chế về đạo đức và pháp lý.....	26
4.3. Demo.....	26
CHƯƠNG 5 - KẾT LUẬN.....	27
5.1. Tóm tắt.....	27
5.2. Hạn chế.....	27
5.3. Hướng phát triển.....	27
TÀI LIỆU THAM KHẢO.....	29

DANH MỤC HÌNH / BẢNG

Bảng 2.1 - Mô tả các đặc trưng của Dataset Pima Indians Diabetes.....	10
Bảng 2.2 - Tỷ lệ giá trị 0 bất thường theo đặc trưng.....	11
Hình 3.1: Bảng so sánh hiệu suất giữa các mô hình.....	15
Hình 3.2: Bảng so sánh chỉ số Recall giữa các mô hình.....	15
Hình 3.3: Các chỉ số hiệu suất của mô hình (metrics).....	16
Hình 3.4: Ma trận nhầm lẫn (Confusion Matrix).....	16
Hình 3.5: Đường cong ROC (ROC Curve).....	18
Hình 3.6: Đường cong học (Learning Curve).....	20
Hình 3.7: Top 10 đặc trưng quan trọng (Feature Importance).....	22

CHƯƠNG 1 - GIỚI THIỆU

1.1. Mô tả bài toán và bối cảnh thực tế

Bệnh tiểu đường là một bệnh mãn tính do rối loạn chuyển hóa đường trong máu. Tuyến tụy không sản xuất đủ insulin (Tiểu đường Type 1) hoặc cơ thể không sử dụng insulin hiệu quả (Tiểu đường Type 2). Theo Tổ chức Y tế Thế giới (WHO), năm 2023 có hơn 537 triệu người trưởng thành mắc bệnh tiểu đường toàn cầu, con số được dự báo sẽ tăng lên 643 triệu vào năm 2030.

Tại Việt Nam, tỷ lệ người mắc tiểu đường gia tăng nhanh chóng, đặc biệt ở khu vực đô thị. Điều đáng lo ngại là đa số bệnh nhân không được phát hiện sớm, dẫn đến các biến chứng nghiêm trọng như mù lòa, suy thận, bệnh tim mạch và hoại tử chi.

Bài toán đặt ra: Xây dựng một mô hình phân loại (Classification) để dự đoán nguy cơ mắc bệnh tiểu đường dựa trên các chỉ số lâm sàng cơ bản (glucose, BMI, huyết áp, tuổi, tiền sử gia đình,...). Mô hình này có thể hỗ trợ bác sĩ và nhân viên y tế sàng lọc bệnh nhân nhanh hơn, giảm chi phí xét nghiệm chuyên sâu và phát hiện bệnh sớm.

Thách thức đặc thù của bài toán:

- Bộ dữ liệu Pima Indians Diabetes có nhiều giá trị 0 bất thường ở các cột như Glucose, BMI, Insulin - thực chất là missing values ẩn.
- Mất cân bằng dữ liệu: 65% không bệnh (Outcome = 0), 35% có bệnh (Outcome = 1).
- Ưu tiên Recall (độ nhạy): Trong y tế, bỏ sót bệnh nhân (False Negative) nguy hiểm hơn nhiều so với báo động nhầm (False Positive).

1.2. Mục tiêu cụ thể

Mục tiêu 1 - Phân tích và làm sạch dữ liệu: Thực hiện EDA toàn diện, phát hiện và xử lý đúng cách các hidden missing values, outliers và class imbalance trong bộ dữ liệu Pima Indians Diabetes.

Mục tiêu 2 - Feature Engineering: Thiết kế và kiểm chứng hiệu quả của ít nhất 3 đặc trưng mới nhằm cải thiện hiệu suất mô hình so với baseline.

Mục tiêu 3 - Xây dựng và so sánh mô hình: Huấn luyện, tinh chỉnh (GridSearchCV) và so sánh ít nhất 3 thuật toán phân loại khác nhau, lựa chọn mô hình tốt nhất dựa trên tiêu chí Recall và AUC.

Mục tiêu 4 - Đạt ngưỡng hiệu suất: Mô hình được chọn đạt $\text{Recall} > 0.80$ và $\text{AUC} \geq 0.80$ trên tập kiểm tra độc lập, không bị data leakage.

Mục tiêu 5 - Triển khai ứng dụng: Hoàn thiện hệ thống 3 tầng (ReactJS + FastAPI + MySQL) với AI Pipeline được đóng gói và phục vụ qua RESTAPI.

Mục tiêu 6 - Theo dõi thực nghiệm: Sử dụng Weights & Biases (Wandb) để ghi nhận, so sánh và tái hiện các thực nghiệm một cách khoa học.

1.3. Lý do lựa chọn mô hình và metric

1.3.1. Lý do chọn mô hình Random Forest

Random Forest là thuật toán Ensemble Learning xây dựng nhiều Decision Tree song song và kết hợp kết quả theo phương pháp bỏ phiếu (voting). Lý do lựa chọn:

- Hiệu suất cao trên dữ liệu y tế không phân phối chuẩn: Random Forest không yêu cầu giả định phân phối chuẩn, phù hợp với đặc điểm lệch phải của các biến như Insulin, DiabetesPedigreeFunction.
- Khả năng chống Overfitting: Cơ chế Bagging (Bootstrap Aggregating) giúp Random Forest ổn định hơn Decision Tree đơn lẻ, đặc biệt khi dữ liệu nhỏ (768 mẫu).
- Feature Importance: Random Forest cung cấp chỉ số tầm quan trọng của từng đặc trưng, giúp giải thích kết quả với bác sĩ.
- Kết quả thực nghiệm: Random Forest đạt $\text{Recall} = 0.889$ và $\text{AUC} = 0.864$, vượt trội so với các mô hình khác.

1.3.2. Lý do ưu tiên metric Recall thay vì Accuracy

Trong bài toán sàng lọc y tế, hai loại sai lầm có mức độ nguy hiểm khác nhau:

- False Negative (FN - Bỏ sót bệnh nhân): Mô hình dự đoán người bệnh là khỏe mạnh. Hậu quả: Bệnh nhân không được điều trị, biến chứng tiến triển. Đây là sai lầm nghiêm trọng hơn.

- False Positive (FP - Báo động nhầm): Mô hình dự đoán người khỏe là bệnh. Hậu quả: Bệnh nhân cần làm thêm xét nghiệm chuyên sâu - có thể xử lý được.

Do đó, nhóm ưu tiên tối đa hóa Recall ($= TP / (TP + FN)$) và chấp nhận giảm Precision. Ngưỡng phân loại (threshold) được hạ xuống 0.35 (thay vì 0.5 mặc định) để tăng độ nhạy.

CHƯƠNG 2 - PHƯƠNG PHÁP

2.1. Mô tả Dataset

Bộ dữ liệu sử dụng là Pima Indians Diabetes Database, được thu thập bởi Viện Quốc gia về Tiểu đường và Bệnh thận (NIDDK), Hoa Kỳ. Dữ liệu bao gồm 768 bản ghi từ phụ nữ gốc Pima (người da đỏ bản địa Arizona), người được khảo sát từ 21 tuổi trở lên.

Bảng 2.1 - Mô tả các đặc trưng của Dataset Pima Indians Diabetes

Tên cột	Kiểu dữ liệu	Mô tả
Pregnancies	int	Số lần mang thai
Glucose	int	Nồng độ glucose trong máu (mg/dL)
BloodPressure	int	Huyết áp tâm trương (mm Hg)
SkinThickness	int	Độ dày nếp gấp da cơ tam đầu (mm)
Insulin	int	Nồng độ insulin huyết thanh ($\mu\text{U/mL}$)
BMI	float	Chỉ số khối cơ thể (kg/m^2)
DiabetesPedigreeFunction	float	Hàm gia phả tiểu đường (nguy cơ di truyền)
Age	int	Tuổi
Outcome	int	Biến mục tiêu: 1 = Có bệnh, 0 = Không bệnh

Thông kê mô tả cơ bản: Dataset có 768 quan sát (không có missing values trực tiếp), trong đó 268 ca có bệnh (34.9%) và 500 ca không bệnh (65.1%). Tuy nhiên, nhiều giá trị 0 bất thường được phát hiện ở các cột Glucose, BloodPressure, SkinThickness, Insulin, BMI – đây thực chất là missing values ẩn cần xử lý.

2.2. Phân tích khám phá dữ liệu (EDA)

2.2.1. Phát hiện giá trị 0 bất thường (Hidden Missing Values)

Kết quả phân tích cho thấy tỷ lệ giá trị 0 bất thường ở các cột quan trọng:

Bảng 2.2 - Tỷ lệ giá trị 0 bất thường theo đặc trưng

Feature	Số giá trị 0	Tỷ lệ (%)
Insulin	374	48.7% (Nghiêm trọng)
SkinThickness	227	29.6% (Cao)
BloodPressure	35	4.6% (Thấp)
BMI	11	1.4% (Thấp)
Glucose	5	0.7% (Rất thấp)

2.2.2. Kiểm định thống kê (T-test & Chi-Square)

Kết quả T-test độc lập so sánh hai nhóm (Outcome = 0 và Outcome = 1) cho thấy 7/8 đặc trưng có sự khác biệt có ý nghĩa thống kê ($p < 0.05$). Đặc biệt Glucose ($T = -14.60$, $p \approx 0$), BMI ($T = -8.47$, $p \approx 0$) và Age ($T = -6.79$, $p \approx 0$) là những biến phân tách mạnh nhất. Kiểm định Chi-Square xác nhận mối quan hệ có ý nghĩa thống kê giữa nhóm tuổi và kết quả bệnh ($\chi^2 = 81.66$, $p \approx 0$).

2.3. Các bước tiền xử lý dữ liệu

2.3.1. Xử lý Missing Values ẩn

Phương pháp: Chuyển đổi giá trị 0 bất thường ở 5 cột (Glucose, BloodPressure, SkinThickness, Insulin, BMI) thành NaN, sau đó điền bằng Trung vị (Median) sử dụng SimpleImputer.

Lý do chọn Median thay vì Mean: Các biến như Insulin có phân phối lệch phải rất mạnh (Skewness = 2.27), giá trị trung bình bị kéo bởi outliers. Median phản ánh "bệnh nhân điển hình" chính xác hơn và ổn định với các giá trị cực đoan.

2.3.2. Xử lý ngoại lai (Outlier Handling)

Phương pháp: IQR Capping (Winsorization) - Tính khoảng tứ phân vị ($IQR = Q3 - Q1$) cho mỗi cột, sau đó sử dụng `.clip` ($Q1 - 1.5 \times IQR$, $Q3 + 1.5 \times IQR$) để giới hạn các giá trị cực đoan về mức biên tương ứng.

Ưu điểm: Giữ nguyên 768 dòng dữ liệu, không mất mẫu; giảm ảnh hưởng của outliers mà không xóa chúng.

2.3.3. Kỹ thuật đặc trưng (Feature Engineering)

Tạo 3 đặc trưng mới từ dữ liệu gốc:

- `Glucose_BMI_Ratio = Glucose / BMI`: Kết hợp hai yếu tố nguy cơ chính thành một chỉ số tương tác, giúp mô hình phân biệt bệnh nhân có glucose cao kết hợp BMI thấp (khác với BMI cao). Thực nghiệm: Feature này đứng thứ 3 về tầm quan trọng (0.1209), vượt cả Insulin (0.0471) và DiabetesPedigreeFunction (0.0998).

- `Age_Group`: Chia tuổi thành 3 nhóm [$< 30 = 0$, $30 - 50 = 1$, $> 50 = 2$]. Lý do: Nguy cơ bệnh tăng theo giai đoạn tuổi, không tuyến tính theo từng năm.

- `BMI_Category`: Phân loại BMI theo tiêu chuẩn WHO [Gầy = 0, Bình thường = 1, Thừa cân = 2, Béo phì = 3]. Lý do: Mô hình học được ngưỡng nguy cơ y tế rõ ràng hơn từ dạng phân loại.

2.3.4. Cân bằng dữ liệu bằng SMOTE

Kỹ thuật SMOTE (Synthetic Minority Over-sampling Technique) tạo ra các mẫu dữ liệu tổng hợp cho nhóm thiểu số (người bệnh) bằng cách nội suy giữa các điểm dữ

liệu gần nhau trong không gian đặc trưng. Sau SMOTE: Tập train cân bằng 400 mẫu mỗi lớp (tổng 800), giúp mô hình học không bị thiên vị nhóm đa số.

2.4. Các mô hình đã sử dụng

2.4.1. Logistic Regression

Mô hình hồi quy logistic áp dụng hàm sigmoid để cho đầu ra là xác suất trong khoảng $[0, 1]$. Thuật toán tối ưu hàm mất mát Log - Loss (Binary Cross - Entropy) [1]. Phù hợp làm baseline do đơn giản và dễ giải thích. Để giảm hiện tượng overfitting, mô hình có thể sử dụng regularization (L1 hoặc L2). Trong đó, L1 giúp lựa chọn đặc trưng bằng cách đưa một số hệ số về 0. Logistic Regression có ưu điểm là đơn giản, dễ triển khai và dễ giải thích, nên thường được sử dụng làm mô hình baseline trong các bài toán phân loại.

2.4.2. Random Forest Classifier

Random Forest là một phương pháp học máy thuộc nhóm Ensemble, dựa trên kỹ thuật Bagging (Bootstrap Aggregating). Mô hình xây dựng nhiều cây quyết định trên các tập con ngẫu nhiên của dữ liệu và đặc trưng, sau đó tổng hợp kết quả dự đoán bằng phương pháp biểu quyết đa số [2].

Nhờ cơ chế lấy mẫu ngẫu nhiên và kết hợp nhiều mô hình, Random Forest giúp giảm phương sai và hạn chế hiện tượng overfitting so với Decision Tree đơn lẻ. Mô hình thường cho hiệu năng tốt và ổn định trên nhiều bài toán phân loại.

2.4.3. Support Vector Machine (SVM)

SVM tìm siêu phẳng (hyperplane) tối ưu tối đa hóa margin giữa hai lớp. Kernel RBF (Radial Basis Function) ánh xạ dữ liệu vào không gian chiều cao hơn để tìm ranh giới phi tuyến tính [3].

Mô hình hoạt động hiệu quả với dữ liệu nhỏ và có khả năng tổng quát hóa tốt, nhưng chi phí tính toán cao khi dữ liệu lớn.

2.4.4. Decision Tree

Decision Tree là mô hình phân loại dựa trên cấu trúc cây, trong đó dữ liệu được phân chia theo các điều kiện tại từng node dựa trên các tiêu chí như Gini hoặc Entropy. Mỗi đường đi từ root đến leaf biểu diễn một quy tắc phân loại [4].

Mô hình dễ hiểu, dễ giải thích nhưng dễ bị overfitting nếu không được kiểm soát độ sâu hoặc điều kiện chia.

2.4.5. Stacking Ensemble

Stacking Ensemble là phương pháp kết hợp nhiều mô hình học máy khác nhau (base models) và sử dụng một mô hình khác (meta-learner) để tổng hợp kết quả dự đoán. Phương pháp này giúp tận dụng điểm mạnh của từng mô hình, từ đó cải thiện hiệu năng tổng thể [5].

Tuy nhiên, Stacking có thể phức tạp và yêu cầu chi phí tính toán cao hơn so với các mô hình đơn lẻ.


CHƯƠNG 3 - KẾT QUẢ

3.1. Bảng so sánh các mô hình

Tất cả mô hình được đánh giá trên cùng tập kiểm tra (154 mẫu) với threshold = 0.35 (trừ Logistic Regression giữ threshold = 0.5 mặc định theo tối ưu GridSearch). Sử dụng RepeatedStratifiedKFold (10 folds, lặp 3 lần) cho GridSearch.

	Model	Accuracy	Precision	Recall	F1-Score	AUC
0	Random Forest	0.714286	0.558140	0.888889	0.685714	0.863889
1	Logistic Regression	0.707792	0.552941	0.870370	0.676259	0.820370
2	Decision Tree	0.759740	0.610390	0.870370	0.717557	0.845370
3	Stacking Ensemble	0.772727	0.637681	0.814815	0.715447	0.845741
4	SVM	0.740260	0.606061	0.740741	0.666667	0.804167

Hình 3.1: Bảng so sánh hiệu suất giữa các mô hình



Hình 3.2: Bảng so sánh chỉ số Recall giữa các mô hình


3.2. Biểu đồ đánh giá mô hình được chọn (Random Forest)

3.2.1. Các chỉ số hiệu suất của mô hình (metrics)

```
Accuracy : 0.7142857142857143
Precision: 0.5581395348837209
Recall    : 0.8888888888888888
F1-score  : 0.6857142857142857
AUC Score: 0.8638888888888888
```

Hình 3.3: Các chỉ số hiệu suất của mô hình (metrics)

3.2.2. Ma trận nhầm lẫn (Confusion Matrix)



Hình 3.4: Ma trận nhầm lẫn (Confusion Matrix)

Các chỉ số định lượng cơ bản: 4 kịch bản dự đoán:

- True Negative (TN = 62): Số ca thực tế Không bệnh và mô hình dự đoán chính xác là Không bệnh. Đây là nhóm người khỏe mạnh được hệ thống xác nhận đúng.

- True Positive (TP = 48): Số ca thực tế Có bệnh và mô hình dự đoán chính xác là Có bệnh. Đây là những bệnh nhân tiểu đường đã được sàng lọc thành công.

- False Positive (FP = 38): Số ca thực tế Không bệnh nhưng mô hình dự đoán nhầm là Có bệnh (Lỗi loại I - Báo động nhầm).

- False Negative (FN = 6): Số ca thực tế Có bệnh nhưng mô hình dự đoán nhầm là Không bệnh (Lỗi loại II - Bỏ sót bệnh nhân).

Đánh giá hiệu suất (Ưu tiên Recall):

- Recall (Độ nhạy) = 0.889. Nhận xét: Mô hình nhận diện chính xác 88.9% bệnh nhân thực tế. Số ca bỏ sót chỉ có 6 trường hợp là một thành công trong bài toán sàng lọc y tế.

- Precision (Độ tin cậy) = 0.558. Nhận xét: Do ưu tiên Recall, độ tin cậy bị sụt giảm. Khi mô hình báo bệnh, có khoảng 55.8% khả năng là chính xác. Tuy nhiên, trong sàng lọc sơ bộ, mức này là chấp nhận được để đổi lấy sự an toàn.

- Accuracy (Độ chính xác tổng thể) = 0.714. Nhận xét: Mô hình duy trì độ chính xác ổn định ở mức 71.4%. Mô hình có khả năng phân loại khá tốt trên toàn bộ tập dữ liệu kiểm tra.

- F1-Score (Cân bằng) = 0.686. Nhận xét: Chỉ số F1 vượt mức 68.6% cho thấy sự cân bằng khá tốt giữa việc phát hiện bệnh và độ tin cậy của dự đoán.

Nhận xét chuyên sâu:


- Đánh đổi để an toàn: Ma trận này cho thấy một chiến lược "thà nhầm còn hơn bỏ sót". Trong y tế, FN (6) nguy hiểm hơn FP (38) rất nhiều, vì bệnh nhân bị bỏ sót sẽ không được điều trị kịp thời. Việc giữ FN ở mức một con số (6) là một tín hiệu rất tích cực.

- Vấn đề False Positive (38): Số lượng báo động nhầm chiếm khoảng 24.7% tổng số mẫu. Điều này có thể gây áp lực lên hệ thống xét nghiệm chuyên sâu, nhưng là chi phí chấp nhận được để đạt được mức Recall $\sim 89\%$.

- Khả năng phân loại: Ma trận nhầm lẫn cho thấy vùng dự đoán đúng (62 và 48) vẫn chiếm ưu thế áp đảo, khẳng định mô hình có nền tảng học tập vững chắc, không bị rơi vào tình trạng đoán mò.

Kết luận: Ma trận nhầm lẫn minh chứng rằng mô hình đã đáp ứng được yêu cầu cơ bản về việc sàng lọc bệnh nhân. Ưu tiên sức khỏe lên hàng đầu thông qua chỉ số Recall cao. Kết quả này hoàn toàn đủ tiêu chuẩn để triển khai giai đoạn thử nghiệm trên hệ thống dự đoán thực tế.

3.2.3. Đường cong ROC và chỉ số AUC



Hình 3.5: Đường cong ROC (ROC Curve)

Các chỉ số định lượng cơ bản:

- Diện tích dưới đường cong ($AUC = 0.86$): chỉ số đại diện cho khả năng phân biệt giữa hai lớp (Có bệnh và Không bệnh).

- Ý nghĩa thống kê: giá trị AUC đạt 0.86, mô hình được xếp vào loại Tốt (Excellent) trong thang đo hiệu suất lâm sàng. Điều này có nghĩa là có 86% xác suất mô hình sẽ xếp hạng một bệnh nhân mắc tiểu đường có điểm tin cậy cao hơn một người không mắc bệnh.

Đánh giá hiệu suất (Khả năng phân loại):

- Độ dốc của đường cong: Đường cong ROC của mô hình đi lên rất nhanh ở giai đoạn đầu (vùng bên trái biểu đồ). Điều này có lợi trong y tế vì mô hình có thể đạt được mức Recall ổn định mà chỉ gây ra một tỷ lệ báo động nhầm rất thấp (dưới 0.2).

- Khoảng cách so với đường cơ sở: Đường biểu diễn của mô hình (màu xanh) nằm cách xa đường đứt đoạn (đường dự đoán ngẫu nhiên $AUC = 0.5$). Điều này chứng minh mô hình đã học được các quy luật thực tế từ dữ liệu lâm sàng thay vì chỉ dự đoán dựa trên xác suất ngẫu nhiên.

Nhận xét chuyên sâu:

- Điểm tối ưu trên đường cong: Khu vực "khúc cua" gần góc trên bên trái nhất chính là ngưỡng cắt (threshold) lý tưởng. Tại đây, mô hình đạt được sự cân bằng tối ưu giữa việc không bỏ sót bệnh nhân và không báo động nhầm quá nhiều.

- Khả năng tách biệt dữ liệu: Với $AUC = 0.86$, mô hình cho thấy sự phân tách rõ rệt giữa phân phối xác suất của hai nhóm. Các đoạn gấp khúc nhẹ trên đường cong cho thấy mô hình vẫn đang xử lý các ca "ranh giới" (như Glucose hoặc BMI ở mức tiền tiểu đường) một cách cẩn trọng.

Kết luận: Chỉ số $AUC = 0.86$ là một minh chứng thuyết phục cho sự thành công của quá trình tiền xử lý và kỹ thuật đặc trưng (Feature Engineering). Nó khẳng định mô hình không chỉ đạt độ chính xác trên các con số định lượng (Accuracy, F1-score) mà còn có năng lực phân biệt đặc trưng bệnh lý rất ổn định. Đây là nền tảng vững chắc

để triển khai hệ thống hỗ trợ ra quyết định lâm sàng trong thực tế, giúp bác sĩ sàng lọc bệnh nhân tiểu đường một cách nhanh chóng và chính xác.

3.2.4. Đường cong học (Learning Curve)



Hình 3.6: Đường cong học (Learning Curve)

Các chỉ số định lượng cơ bản:

- Training Score: Duy trì ở mức rất cao, dao động quanh khoảng 0.89 - 0.96.
- Validation Score: Thấp hơn đáng kể so với Training Score, tăng trưởng và đạt ngưỡng ổn định quanh mức 0.72 - 0.74 khi mẫu huấn luyện vượt quá 200.
- Khoảng cách (Gap): Tồn tại một khoảng cách rõ rệt giữa hai đường, trung bình khoảng 15% - 20%.

Đánh giá tình trạng Overfitting/Underfitting:

- Về Underfitting (Lỗi chệch): Mô hình không bị Underfitting. Cả hai đường đều đạt mức Accuracy khá cao (>0.72). Điều này cho thấy mô hình đủ phức tạp để học được các quy luật của bộ dữ liệu tiêu đường.

- Về Overfitting (Lỗi quá khớp): Mô hình đang có dấu hiệu Overfitting. Khoảng cách lớn giữa hai đường cho thấy mô hình đang "ghi nhớ" một số đặc điểm riêng biệt của tập huấn luyện mà chưa tổng quát hóa tốt sang tập dữ liệu kiểm tra.

Nhận xét chuyên sâu:


- Độ nhạy với dữ liệu: Mô hình học rất nhanh. Chỉ cần khoảng 150 - 200 mẫu, Validation Score đã đạt đến vùng tiệm cận bão hòa. Điều này cho thấy các đặc trưng (features) trong bộ dữ liệu tiêu đường này có tính phân loại khá rõ ràng.

- Ngưỡng bão hòa: Khi Training Size vượt quá 400, đường Validation có xu hướng đi ngang. Điều này cho thấy mô hình đã khai thác gần như tối đa thông tin từ bộ dữ liệu hiện tại. Hiệu suất AUC đạt 0.86 là minh chứng cho năng lực phân loại rất mạnh mẽ của kiến trúc này.

- Khả năng tổng quát hóa: Việc đường Validation không bị sụt giảm ở cuối biểu đồ cho thấy Random Forest giữ được cái nhìn khách quan tốt khi quy mô dữ liệu tăng lên, không bị sa đà vào việc học vẹt các chi tiết nhỏ.

Kết luận: Mô hình Random Forest hiện tại đang nằm ở trạng thái cân bằng tương đối tốt. Tuy có dấu hiệu Overfitting (đặc điểm chung của các dòng thuật toán dựa trên cây), nhưng nó vẫn mang lại Recall ($\sim 88.9\%$) và AUC (~ 0.86) cao trong các thử nghiệm, phù hợp cho bài toán sàng lọc y tế.

3.2.5. Top 10 đặc trưng quan trọng (Feature Importance)



Hình 3.7: Top 10 đặc trưng quan trọng (Feature Importance)

Thứ hạng và Tỷ trọng các biến số:

- Biến có tỷ trọng cao nhất (Glucose): chiếm ưu thế với khoảng 20.6% tổng trọng số quyết định. Điều này cho thấy Glucose là yếu tố quan trọng nhất để mô hình thực hiện các lần chia nhánh (splits) đầu tiên.

- Nhóm biến hỗ trợ:

- + BMI & Glucose_BMI_Ratio: Xếp vị trí thứ hai và thứ ba với trọng số lần lượt là ~16.5% và ~12.1%. Đây là các chỉ số nền tảng giúp mô hình tăng độ chính xác khi đối mặt với các ca bệnh có mức Glucose ở ngưỡng ranh giới.

- + Age (~10.5%): Xếp vị trí thứ tư, đóng vai trò quan trọng trong việc phân loại các nhóm bệnh nhân theo độ tuổi.

- + DiabetesPedigreeFunction (~10.0%): Đứng ngay sau Age, phản ánh yếu tố di truyền trong nguy cơ mắc bệnh.

- Nhóm biến ảnh hưởng trung bình:

- + SkinThickness (~ 7.7%) và BloodPressure (~6.7%) góp phần hỗ trợ mô hình trong các trường hợp cần thêm thông tin sinh lý để phân biệt.

- Nhóm biến ảnh hưởng thấp:

- + Các biến như Insulin (~ 4.7%), BMI_Category (~ 4.5%), Pregnancies (~4.3%) giúp mô hình tinh chỉnh dự đoán trong các ca bệnh phức tạp.

Đánh giá tính hợp lý về mặt y sinh:

- Sự tương quan với thực tế lâm sàng: Kết quả này hoàn toàn khớp với kiến thức y khoa hiện đại. Chỉ số đường huyết (Glucose) là tiêu chuẩn vàng để chẩn đoán tiểu đường. Việc mô hình tự động tập trung vào Glucose chứng minh dữ liệu có chất lượng tốt và mô hình đã học được quy luật sinh học cốt lõi thay vì các số liệu nhiễu.

- Vai trò của các yếu tố nguy cơ: BMI và Age là hai yếu tố nguy cơ hàng đầu dẫn đến kháng insulin. Sự xuất hiện của chúng ở nhóm đầu khẳng định mô hình có khả năng giải thích cao, giúp y bác sĩ dễ dàng tin tưởng vào kết quả dự đoán.

Nhận xét về kỹ thuật và thuật toán:

- Ưu điểm của Random Forest: Random Forest phân bổ trọng số đa dạng giúp mô hình bền vững hơn. Nếu một bệnh nhân bị thiếu chỉ số Glucose, mô hình vẫn có thể dựa vào BMI, Age và các biến khác để đưa ra dự đoán có độ chính xác nhất định.

- Tối ưu hóa đặc trưng: Biến BMI_Category (~4.5%) có mức đóng góp thấp hơn so với BMI liên tục, cho thấy trong thuật toán dựa trên cây, việc sử dụng giá trị liên tục hiệu quả hơn so với việc chia nhóm, vì giữ lại được nhiều thông tin hơn cho mô hình.

Kết luận: Phân tích Feature Importance khẳng định mô hình Random Forest đã xây dựng được một hệ thống quy tắc dự đoán logic và bám sát thực tế y tế. Sự tập trung vào các biến Glucose, BMI và Glucose_BMI_Ratio đảm bảo mô hình có tính ứng dụng cao trong việc sàng lọc nhanh, giúp nhân viên y tế tập trung vào những chỉ số quan trọng nhất của bệnh nhân để đưa ra kết luận chính xác.

3.3. Lý do chọn Random Forest làm mô hình triển khai

Nhóm quyết định chọn Random Forest (kết hợp tối ưu ngưỡng 0.35) làm mô hình triển khai cuối cùng vì các lý do sau:

- Recall cao nhất (0.888889): Đảm bảo an toàn tối đa cho bệnh nhân trong giai đoạn tầm soát.
- Độ tin cậy vững chắc: Chỉ số AUC (0.863889) khẳng định năng lực phân loại thực tế rất tốt.
- Sự cân bằng thực tiễn: Mặc dù F1-score không cao nhất, mô hình vẫn đạt được sự thỏa hiệp hợp lý giữa độ nhạy lâm sàng và khả năng ứng dụng thực tế trong hệ thống hỗ trợ ra quyết định.

Kết luận: Với sự hỗ trợ của thuật toán Random Forest, hệ thống dự đoán tiêu đường đã sẵn sàng để hỗ trợ nhân viên y tế sàng lọc bệnh nhân một cách hiệu quả, chính xác và giảm thiểu rủi ro bỏ sót ca bệnh.

CHƯƠNG 4 - ỨNG DỤNG THỰC TẾ

4.1. Scenario sử dụng

4.1.1. Kịch bản 1: Sàng lọc bệnh nhân tại cơ sở y tế

- Người dùng: Y tá/điều dưỡng tại phòng khám đa khoa hoặc bệnh viện tuyến huyện.
- Bối cảnh: Bệnh nhân đến khám định kỳ, chưa có kết quả xét nghiệm máu chuyên sâu.
- Đầu vào: Y tá nhập các chỉ số đo được ngay tại phòng khám: số lần mang thai, glucose (đo bằng máy đơn giản), huyết áp, BMI, tuổi.
- Đầu ra: Hệ thống hiển thị "Nguy cơ mắc tiểu đường cao, cần đi khám" hoặc "Không có dấu hiệu tiểu đường".
- Giá trị: Giúp y tá phân loại ưu tiên bệnh nhân cần xét nghiệm HbA1c hoặc OGTT (oral glucose tolerance test) ngay, tiết kiệm thời gian và chi phí.

4.1.2. Kịch bản 2: Theo dõi sức khỏe cá nhân

- Người dùng: Cá nhân có tiền sử gia đình mắc tiểu đường, người thừa cân/béo phì muốn tự theo dõi sức khỏe.
- Bối cảnh: Người dùng tự nhập các chỉ số sau khi đo tại nhà hoặc sau khám sức khỏe định kỳ.
- Đầu vào: các chỉ số lâm sàng (có thể lấy từ kết quả khám gần nhất).
- Đầu ra: Hệ thống hiển thị "Nguy cơ mắc tiểu đường cao, cần đi khám" hoặc "Không có dấu hiệu tiểu đường".
- Giá trị: Nâng cao ý thức phòng bệnh chủ động, khuyến khích khám sức khỏe định kỳ.

4.2. Hạn chế khi triển khai

4.2.1. Hạn chế về dữ liệu

- Dataset chỉ bao gồm phụ nữ gốc Pima người da đỏ bản địa tại Arizona - không đại diện cho toàn bộ dân số, đặc biệt người Việt Nam. Cần kiểm định trên dữ liệu Việt Nam trước khi triển khai đại trà.

- Số lượng mẫu nhỏ (768): Mô hình có thể chưa học được hết các biến thể phức tạp của bệnh.

- Thiếu các đặc trưng quan trọng như HbA1c, tiền sử dùng thuốc, chế độ ăn uống.

4.2.2. Hạn chế về môi trường và kỹ thuật

- Hiện tại chạy local (localhost:3000): Cần triển khai lên server thực (cloud) để sử dụng rộng rãi.

- Chưa có cơ chế xác thực người dùng và phân quyền truy cập.

- Model cần được cập nhật định kỳ khi có dữ liệu mới.

4.2.3. Hạn chế về đạo đức và pháp lý

- Mô hình chỉ là công cụ hỗ trợ quyết định, không thay thế chẩn đoán của bác sĩ. Cần có bác sĩ xem xét kết quả cuối cùng.

- Dữ liệu y tế cần được bảo mật theo quy định (HIPAA, Luật An toàn thông tin mạng Việt Nam).

- Nguy cơ thiên kiến (bias): Mô hình có thể kém chính xác hơn với các nhóm dân số chưa có trong dataset gốc.

4.3. Demo

- Luồng dữ liệu: Người dùng nhập 8 chỉ số lâm sàng trên giao diện ReactJS → Gửi POST request đến /predict endpoint của FastAPI → FastAPI tính thêm 3 features mới (Glucose_BMI_Ratio, Age_Group, BMI_Category) → Đưa vào AI Pipeline (RandomForest) để dự đoán → Lưu kết quả vào MySQL → Trả về kết quả và thông điệp cho người dùng.

- Link demo:

https://drive.google.com/drive/folders/1c1VHrqrN15ZKwrWLKRqEKZ6oMHHctq_?usp=sharing

CHƯƠNG 5 - KẾT LUẬN

5.1. Tóm tắt

Bài tập lớn này đã hoàn thành các mục tiêu đề ra:

- Xây dựng thành công pipeline ML hoàn chỉnh: EDA → Preprocessing → Feature Engineering (3 features mới) → Modeling → Evaluation, đảm bảo không bị data leakage.
- So sánh 5 thuật toán khác nhau một cách hệ thống, sử dụng GridSearchCV và RepeatedStratifiedKFold để tìm hyperparameter tối ưu.
- Đạt Recall = 0.889 với Random Forest trên tập kiểm tra, vượt mục tiêu đề ra (≥ 0.80). Chỉ bỏ sót 6/54 người thực sự có bệnh.
- Triển khai hệ thống ứng dụng 3 tầng hoàn chỉnh: Frontend ReactJS, Backend FastAPI, Database MySQL, AI Pipeline được đóng gói bằng joblib.
- Sử dụng Weights & Biases (WandB) để theo dõi và so sánh thực nghiệm một cách khoa học.

5.2. Hạn chế

Dataset nhỏ (768 mẫu) và chưa đại diện cho dân số Việt Nam - cần thu thập thêm dữ liệu địa phương.

Precision thấp (0.558): Tỷ lệ báo động nhầm còn cao, có thể gây áp lực lên hệ thống xét nghiệm.

Hệ thống chưa có cơ chế tự động cập nhật mô hình (MLOps pipeline) khi có dữ liệu mới.

Giao diện frontend còn đơn giản, chưa có tính năng hiển thị lịch sử và phân tích xu hướng sức khỏe theo thời gian.

5.3. Hướng phát triển

Thu thập và bổ sung dữ liệu từ bệnh viện Việt Nam, đặc biệt thêm đặc trưng HbA1c và Fasting Glucose - các chỉ số tiêu chuẩn chẩn đoán tiểu đường theo IDF.

Thử nghiệm các mô hình phức tạp hơn: XGBoost, LightGBM, Neural Network - có tiềm năng cải thiện cả Recall và Precision đồng thời.

Xây dựng MLOps pipeline: Tự động retraining khi có dữ liệu mới, monitoring model performance, A/B testing.

Triển khai lên cloud (AWS/GCP/Azure) với HTTPS, xác thực JWT, đảm bảo bảo mật dữ liệu y tế.

Phát triển ứng dụng di động (Mobile App) để người dùng có thể theo dõi sức khỏe mọi lúc mọi nơi.

Hợp tác với bác sĩ lâm sàng để thêm knowledge-based rules và tăng tính tin cậy trong môi trường y tế thực tế.

TÀI LIỆU THAM KHẢO

- [1] C. M. Bishop, Pattern Recognition and Machine Learning. New York, NY, USA: Springer, 2006.
- [2] L. Breiman, “Random forests,” Machine Learning, vol. 45, no. 1, pp. 5–32, 2001.
- [3] C. Cortes and V. Vapnik, “Support-vector networks,” Machine Learning, vol. 20, no. 3, pp. 273-297, 1995.
- [4] J. R. Quinlan, “Induction of decision trees,” Machine Learning, vol. 1, no. 1, pp. 81-106, 1986.
- [5] D. H. Wolpert, “Stacked generalization,” Neural Networks, vol. 5, no. 2, pp. 241-259, 1992.